Survey 0: Bài toán Speech2Text

🎯 **Mục tiêu sáng nay**: Làm rõ **Input/Output** của bài toán Speech-to-Text (ASR), tìm hiểu một số kiểu model.

Part 1 — Bài toán & I/O (Problem framing)

Part này trả lời: "Mình đang giải bài toán gì, và hệ thống nhận gì/trả gì?"

- **Bài toán**: Automatic Speech Recognition (ASR)
  - Chuyển **tín hiệu tiếng nói** → **văn bản đặc biệt là xử lí ngôn ngữ tiếng Việt**.
- **Input huấn luyện đầu vào** (đầu vào)
  - Đầu tiên, chúng ta sẽ có input là ở dạng voice, sau đó được chuyển thể thành một dạng tần số vật lý (Mel Spectrogram)
    - Mel Spectrogram là một cách để bóc tách dữ liệu âm thanh đầu vào thành dữ liệu tần số để dễ dàng xử lí (ví dụ tần số của con người khi nói chuyện sẽ khoảng từ 0 - 1kHz).
    - Mel Spectrogram có thể được nhận lấy từ phép biến đổi Fourier

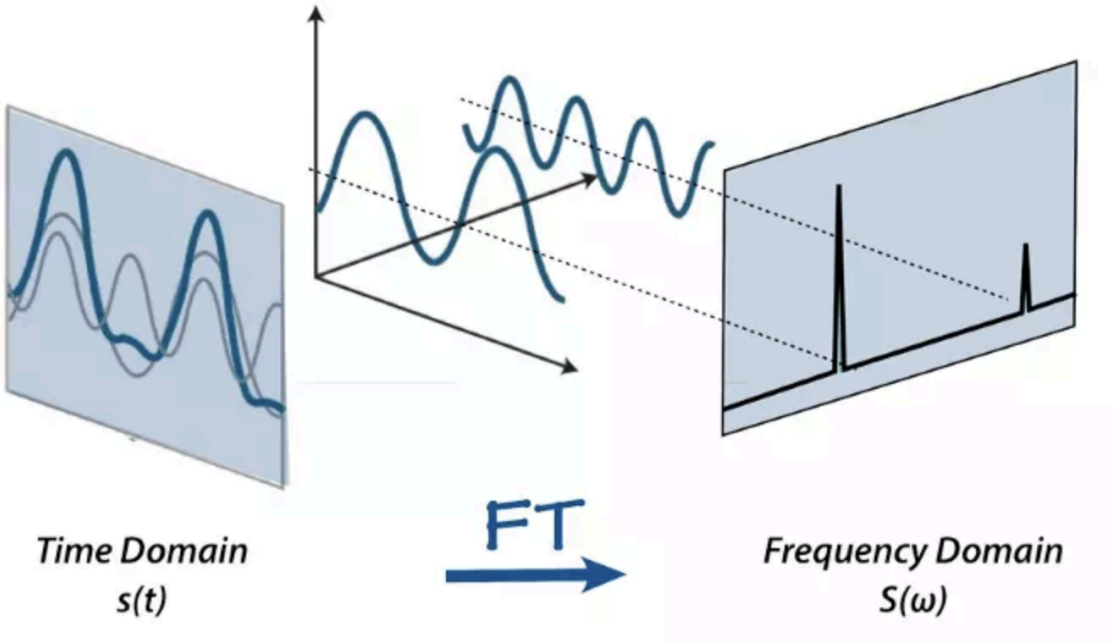

- Tiếp theo, sau khi xử lí đặc trưng (biến đổi đầu vào của Mel Spectrogram thành vector thông qua một lớp CNN nhỏ để biết một số đặc trưng chứ không đoán mù ?), ta sẽ có cặp input đầu vào và đầu ra và đưa qua các mô hình tính toán được xây dựng như thông thường (Transformer).
- Tất nhiên, khi đi qua mô hình như Transformer, các tín hiệu âm thanh sẽ được xử lí toàn cục chứ không chỉ để ý đầu từ và cuối từ để có thể xử lí một số trường hợp như:
    - Nói ngọng
    - Nói nuốt chữ
    - ...
- Sau đó, trong khi huấn luyện, model cũng sử dụng encoder||decoder như bình thường nhưng trong một số tác vụ ví dụ như masking từ và đoán trong encoder thì không cần đoán chính xác mà dựa vào một số hàm loss như InfoNCE Loss,...
- Nhưng có một số vấn đề độ dài của chuỗi âm thanh đầu vào luôn dài hơn rất nhiều so với chuỗi ký tự đầu ra, và chúng ta không biết chữ nào tương ứng với mili-giây thứ mấy. Để thực hiện việc "matching" này, thuật toán tiêu chuẩn được sử dụng là **CTC**.

Hiểu đơn giản thì chúng ta đang làm việc với các đoạn âm thanh và tần số liên tục. Mỗi từ sẽ có một biểu diễn tần số khác nhau và việc của chúng ta là đi dự đoán chúng cũng như tìm được

Part 2: Có hai kiểu bài toán cho speech to text:

- Model cho ra output realtime.
- Model cho ra output sau khi nghe hết câu.